

Web Sistemak

KUDEAKETAREN ETA INFORMAZIO SISTEMEN
INFORMATIKAREN INGENIARITZAKO GRADUA

Sistemen Ingeniaritza eta Automatika saila

Web Scrapping

HTML-aren azterketa eta parseatzea Deskargatutako vs Bistaratutako HTML-a

Oskar Casquero (oskar.casquero@ehu.eus)

María Luz Álvarez Gutiérrez (marialuz.alvarez@ehu.eus)



Esta obra está bajo una [licencia de Creative Commons Reconocimiento-CompartirIgual 4.0 Internacional](https://creativecommons.org/licenses/by-sa/4.0/).



Universidad
del País Vasco

Euskal Herriko
Unibertsitatea


BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

WEB SCRAPING

- HTML orrialde baten egitura.
- Adibidea: BILATUn bilaketak egiten dituen bezeroa programatzea.
 - HTML-aren azterketa: Nabigatzailearen garatzaileentzako tresnak: Inspector.
 - HTML-aren parseatzea: BeautifulSoup liburutegia.
- Deskargatutako vs Bistaratutako HTML-a.

WEB SCRAPING

```
<html>
  <head>
    <title>título</title>
    <script>
      var data = new Date();
      document.write("Client Date: ");
      document.write(data);
    </script>
  </head>
  <body>
    <p>
      <span class="a">bla</span>
      <span class="a">bla</span>
      <span class="a">bla</span>
    </p>
    <div id="identifier">
      <a href="http://...">
        
        <span>bla</span>
      </a>
    </div>
  </body>
</html>
```




DOM (Document Object Model)

Adibidea: BILATU zerbitzuan bilaketak egiten dituen bezeroa programatzea

WEB SCRAPING

- Ariketa: EHUKo direktorioan kontsultak egiteko bezero bat programatuko dugu, emaitzen izena, abizenak eta esteka jasotzen dituen laburpen bat erakusteko
- Bilaketa orriaren egitura aztertzeko: nabigatzailearen garatzaileentzako *Inspector* tresna.
- Pythonen, HTML-a parseatzeko: *BeautifulSoup* liburutegia.
 - Dokumentazioa: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>



Adibidea: BILATU zerbitzuan bilaketak egiten dituen bezeroa programatzea

WEB SCRAPING

- Bidali beharreko datuen izenak eta horiek bidaliko diren endpointa (URLa) zehaztea.

```
# HTTP eskaera  
metodo = "POST" # <form> elementuan "method" atributua  
uri = "https://www.ehu.eus/bilatu/buscar/sbilatu.php" # <form> elementuan "action" atributua  
cabeceras = { 'Host': 'www.ehu.eus',  
              'Content-Type': 'application/x-www-form-urlencoded' }  
datos_dict = { 'abi_ize': sys.argv[1] } # CLI-tik balioa irakurri  
datos_form = urllib.parse.urlencode(datos_dict) # datuak inprimaki formatuan  
cabeceras['Content-Length'] = str(len(datos_form))
```

Inspector-eko bilaketa-barra erabili. Bilatu formularioa deklaratzeko aukera ematen duen testu-katea ("Apellidos/ Nombre").

form elementuaren action atributuak bidalketaren endpointa adierazten du.

input elementuaren name atributuak datuaren izena zehazten du, zerbitzariak bidalitako datuak identifikatu ditzan.

Inspector-eko bilaketa-barra erabili. Bilatu formularioa deklaratzeko aukera ematen duen testu-katea ("Apellidos/ Nombre").

form elementuaren action atributuak bidalketaren endpointa adierazten du.

input elementuaren name atributuak datuaren izena zehazten du, zerbitzariak bidalitako datuak identifikatu ditzan.

WEB SCRAPING

- Datuak HTML kodean kokatu. Nola aurki ditzakegu DOM zuhaitza nabigatuz?

Datuen kokapena HTML kodean:

- Datu bakoitzeko, bereizmenik gabeko esteka (a elementua) bana dago.
- Esteka bakoitza gelaxka (td elementua) batean dago, zeinen class atributuaren balioa "fondo_listado" da.
- Gelaxka bakoitza bereizmenik gabeko errenkada (tr elementua) batean dago.
- Errenkadak taula (table elementua) batean dagoz, zeinen class atributuaren balioa "cuadro_prueba" da.

DOM zuhaitzaren errotik, hainbat modu daude datuetara iristeko:

- class atributuaren balioa "fondo_listado" duten gelaxkak bilatuz. Horretarako, ziurtatu behar da mota honetako gelaxka agerpen kopurua datu kopuruaren berdina dela (kasu honetan, 6).
- Gelaxka mota hori web orriko beste atal batean erabiliko balitz, bilaketa class atributuaren balioa "cuadro_prueba" duen taulara mugatu beharko litzateke. Horretarako, ziurtatu behar da taula mota hau behin bakarrik agertzen dela.

```
# HTML kodea parseatu behar ditugun datuak ateratzeko
ref_doc = BeautifulSoup(html, 'html.parser') # zuhaitzaren errora apuntatzen du
ref_tabla = ref_doc.find_all('table', {'class': 'cuadro_prueba'}) # taulara apuntatzen du
ref_enlaces = ref_tabla[0].find_all('a') # taulako estekak dituen arraya itzultzen du
for idx, each in enumerate(ref_enlaces):
    nom_ape = each.text
    enlace = "https://www.ehu.eus/" + each.get('href')
    print(str(idx) + " " + nom_ape + " " + enlace)
```

The screenshot shows the BILATU web application interface. The search results are displayed in a table with the following structure:

Albaina	Albaina
ALBAINA LOPEZ DE ARMENTIA, INIGO	ALBAINA LOPEZ DE ARMENTIA, INIGO
ARMENTIA DIAZ DE TUESTA, AINTZANE	ARMENTIA DIAZ DE TUESTA, AINTZANE
ARMENTIA GALAN, GORKA	ARMENTIA GALAN, GORKA
ARMENTIA RODRIGO, ELENA MIRIAM	ARMENTIA RODRIGO, ELENA MIRIAM
ARMENTIA SANTAMARIA, JOSEBA	ARMENTIA SANTAMARIA, JOSEBA
CANO ARMENTIA, ARKAITZ	CANO ARMENTIA, ARKAITZ

Deskargatutako vs Bistaratutako HTML-a

WEB SCRAPING

Nabigatzaileak JavaScript kodea exekutatzen du orria bistaratu aurretik.
JavaScript kodeak HTML-aren egitura eta edukia aldatzeko gaitasuna du.

Deskargatutako HTML-a

```
...  
<body>  
  Server Date: Fri Mar 04 08:43:33 CET 2016  
  <br/>  
  <script language="javascript">  
    var data = new Date();  
    document.write("Client Date: ");  
    document.write(data);  
  </script>  
</body>
```

**HTML orri bat sortu
eduki honekin**

Firefox-en

HTML-a zabaldu


Bistaratutako HTML-a

```
Server Date: Fri Mar 04 08:43:33 CET 2016  
Client Date: Fri Mar 04 08:43:34 GMT+0100
```

Deskargatutako vs Bistaratutako HTML-a

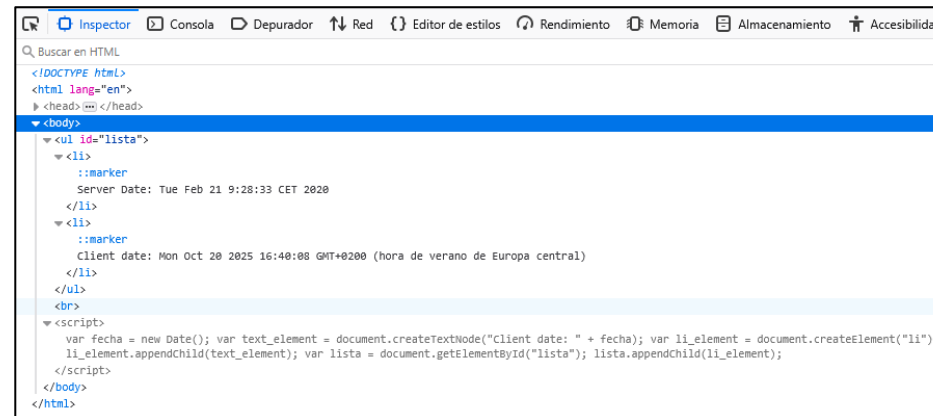
WEB SCRAPING

- Nabigatzailearen "Iturburu-kodea ikusi" aukerak deskargatutako HTML kodea ikustea ahalbidetzen du.



```
1 <!DOCTYPE html>
2 <html lang="en">
3   <head>
4     <meta charset="UTF-8"/>
5     <title>PESTAÑA</title>
6   </head>
7   <body>
8     <ul id="lista">
9       <li>Server Date: Tue Feb 21 9:28:33 CET 2020</li>
10    </ul>
11    <br/>
12    <script>
13      var fecha = new Date();
14      var text_element = document.createTextNode("Client date: " + fecha);
15      var li_element = document.createElement("li");
16      li_element.appendChild(text_element);
17      var lista = document.getElementById("lista");
18      lista.appendChild(li_element);
19    </script>
20  </body>
21 </html>
22
```

- Nabigatzailearen "Inspector" tresnak bistaratutako HTML kodea ikustea ahalbidetzen du.



```
<!DOCTYPE html>
<html lang="en">
  <head>
  </head>
  <body>
    <ul id="lista">
      <li>
        ::marker
        Server Date: Tue Feb 21 9:28:33 CET 2020
      </li>
      <li>
        ::marker
        Client date: Mon Oct 20 2025 16:40:08 GMT+0200 (hora de verano de Europa central)
      </li>
    </ul>
    <br>
    <script>
      var fecha = new Date(); var text_element = document.createTextNode("Client date: " + fecha); var li_element = document.createElement("li");
      li_element.appendChild(text_element); var lista = document.getElementById("lista"); lista.appendChild(li_element);
    </script>
  </body>
</html>
```