

Web Sistemak

KUDEAKETAREN ETA INFORMAZIO SISTEMEN
INFORMATIKAREN INGENIARITZAKO GRADUA

Sistemen Ingeniaritza eta Automatika saila

Web Scrapping

HTML-a parseatu

Deskargatutako vs Bistaratutako HTML-a

Oskar Casquero (oskar.casquero@ehu.eus)

María Luz Álvarez Gutiérrez (marialuz.alvarez@ehu.eus)



Esta obra está bajo una [licencia de Creative Commons Reconocimiento-CompartirIgual 4.0 Internacional](https://creativecommons.org/licenses/by-sa/4.0/).



Universidad
del País Vasco

Euskal Herriko
Unibertsitatea

BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

WEB SCRAPING

- HTML-a bistaratzea Selenium+Geckodriver erabiliz.
- Adibidea: Aplikazio bat programatu, Google Images-en bilaketa baten emaitza diren irudiak deskargatzeko.

WEB SCRAPING

- Selenium nabigatzailearen erabilera automatizatzeko tresna da.



```
import time
from selenium import webdriver
from selenium.webdriver.firefox.options import Options

# nabigatzailea zabaldu
options = Options()
options.binary_location = r'C:\Program Files\Mozilla Firefox\firefox.exe'
browser = webdriver.Firefox(options=options)

# Google Images-en bilaketa abiarazi
uri = "https://www.google.com/search?q=coches&tbm=isch"
browser.get(uri)



# behera scroll egin 5 segunduz
for i in range(1, 5):
    browser.execute_script("window.scrollTo(0, window.innerHeight);")
    time.sleep(1)

# bistaratutako web orrialdearen HTML kodea lortu
html = browser.page_source
browser.close()
```

Adibidea: Google Images-eko irudiak deskargatzea

WEB SCRAPING

Aplikazio bat programatu nahi da, Google Images-en bilaketa baten emaitza diren irudiak automatikoki deskargatu eta local-eko karpeta batean gorde ditzan.



HTML-aren egitura aztertu irudiak non dauden jakiteko


Adibidea: Google Images-eko irudiak deskargatzea

- Firefox erabiliz, Google Images-en “coches” bilatu: <https://www.google.com/search?q=coches&tbm=isch>
- Inspector erabiliz, deskargatutako orrialdearen HTML kodea aztertu irudiak kokatzeko.

Kotxeen irudiak `img` elementuetan daude, eta haien `class` atributua “`YQ4gaf`” da

Baina badaude atributu balio hori duten, beste irudi batzuk, kotxeekin bat ez datozenak.

Apur bat gehiago aztertuz gero, ikus dezakegu kotxeen irudiak `div` elementuen barruan daudela, eta haien `class` atributua “`q1MG4e mNslhb`” dela.



Deskargatutako orrialdea eta bistaratutakoa bat datoz?

Adibidea: Google Images-eko irudiak deskargatzea


```
# HTTP eskaera
metodo = "GET"
uri = "https://www.google.com/search?q=coches&tbm=isch"
cabeceras = { 'Host': 'www.google.com', }

print(metodo + " " + uri)
respuesta = requests.get(uri, headers=cabeceras, allow_redirects=False)

# HTTP erantzuna
codigo = respuesta.status_code
razon = respuesta.reason
print(str(codigo) + " " + razon)
html = respuesta.content # bilaketaren emaitzen orrialdearen HTML kodea
print(html)

# HTML kodea parseatu, behar ditugun datuak ateratzeko
ref_doc = BeautifulSoup(html, 'html.parser') # zuhaitzaren errora apuntatzen du
ref_divs = ref_doc.find_all('div', {'class': 'q1MG4e mNslhb'}) # divs-etara apuntatzen du
for idx, each in enumerate(ref_divs):
    print(idx, each)
```

EZ DU EMAITZIK ITZULTZEN!



```
Run prueba_google_images_requests x
C:\Users\cvzcaio\PycharmProjects\atIC2025\venv\Scripts
GET https://www.google.com/search?q=coches&tbm=isch
200 OK
b'<!DOCTYPE html PUBLIC "-//WAPFORUM//DTD XHTML Mobil
Process finished with exit code 0
```


- Deskargatutako orrialdearen HTML kodea aztertu “Iturburu-kodea ikusi” erabiliz.

[illegible]

- Kodeak HTML egitura sinplea eta JavaScript (JS) kode asko du.
- JS kodea arreta handiz aztertuz gero, ondoriozta daiteke `setImagesSrc()` funtzioak irudiak HTML-aren DOM-ean sartzen dituela.
- Deskargatutako orrialdean kotxeen irudiak dituzten *img* elementuak ez daudenez, ezin da *requests* erabili *BeautifulSoup* hornitzeko.
- Beraz, Selenium erabili behar da orrialdea bistaratzeko.

Selenium erabili orrialdea bistaratzeko

Adibidea: Google Images-eko irudiak deskargatzea


```
# Nabigatzailea zabaldu
options = Options()
options.binary_location = r'C:\Program Files\Mozilla Firefox\firefox.exe'
browser = webdriver.Firefox(options=options)

# Google Images-en bilaketa abiarazi
uri = "https://www.google.com/search?q=coches&tbm=isch"
browser.get(uri) # behera scroll egin 5 segunduz
for i in range(1, 5):
    browser.execute_script("window.scrollTo(0, window.innerHeight);")
    time.sleep(1)

# bistaratutako web orrialdearen HTML kodea lortu
html = browser.page_source
browser.close()

# HTML kodea parseatu behar ditugun datuak ateratzeko
ref_doc = BeautifulSoup(html, 'html.parser') # apunta a raíz del árbol
ref_divs = ref_doc.find_all('div', {'class': 'q1MG4e mNsIhb'}) # apunta a los divs
for idx, each in enumerate(ref_divs):
    print(idx, each)
```

ORAIN BADAUZKAGU EMAITZAK!



```
Run prueba_google_images_selenium
82 <div class="q1MG4e mNsIhb" style="max-height:183px;max-width:275px"><img alt="Los dos coches más vendidos del mundo en 2021
83 <div class="q1MG4e mNsIhb" style="max-height:168px;max-width:299px"><img alt="Los 28 coches más caros y lujosos del mundo, a
84 <div class="q1MG4e mNsIhb" style="max-height:168px;max-width:299px"><img alt="Estos son los 10 coches más pequeños creados p
85 <div class="q1MG4e mNsIhb" style="max-height:159px;max-width:318px"><img alt="Conducir un coche de lujo? Sí, gracias al rent
86 <div class="q1MG4e mNsIhb" style="max-height:183px;max-width:275px"><img alt="5 motivos por los que comprar un BMW | bmwmome
|
Process finished with exit code 0
```


Adibidea: Google Images-eko irudiak deskargatzea

Base64-n dauden irudiak deskodetu eta HTTP eskaerak egin estekatutako irudiak deskargatzeko.

